

Parallele Text-Suche

Projekt 9

Projektbeschreibung und Ziele

In diesem Projekt entwickeln Sie ein System zur Suche in sehr großen Textdatenmengen. Ziel ist es, effizient herauszufinden, ob bestimmte Wörter, Wortfolgen oder Muster in einem oder mehreren Texten vorkommen und an welcher Stelle. Der Fokus liegt weniger auf komplexen Algorithmen aus der Computergrafik oder Numerik, sondern auf effizienten Datenstrukturen, paralleler Verarbeitung und Skalierbarkeit.

Zunächst laden Sie eine oder mehrere große Textdateien ein (z.B. Logfiles oder Bücher) und zerlegen diese in geeignete Verarbeitungseinheiten. Anschließend implementieren Sie eine Methode, um nach einem oder mehreren Suchbegriffen zu suchen (exakte Wortsuche und Sätze).



Ziele

Implementieren Sie die folgenden Funktionalitäten in Ihrem Projekt. Setzen Sie diese sowohl sequentiell, als auch parallel um.

- 1. Suche von Wörtern und Sätzen in großen Textdateien**
- 2. Gleichzeitige Suche von Wörtern und Sätzen aus einer Liste**
- 3. Ausgabe der Stellen, an denen ein Match gefunden wurde**

Die Menge an Text, sowie die Menge an Suchbegriffen und Sätzen sollen variiert werden. Versuchen Sie auch ein Buch zu laden und dort Ihre Suche durchzuführen.

Technologien

Nutzen Sie für Ihr Projekt folgende Technologien:

- **OpenMP** (Multithreading auf der CPU)
- **MPI** (Verteilung der Arbeit auf mehrere Prozesse und Nodes)
- **CUDA** oder **OpenCL** (Wählen Sie eine der beiden Technologien aus)

Das Ziel beim Einsatz der verschiedenen Technologien ist es, die kürzeste Laufzeit gegenüber der sequentiellen Implementierung zu erreichen. Dieser Speedup kann durch den Einsatz einzelner Technologien oder durch eine Kombination derselben erzielt werden. Da jede Technologie unterschiedliche Stärken und Schwächen besitzt, müssen Sie für jede Operation analysieren und begründen, welche Technologie geeignet ist und welche Vorteile oder Nachteile sich daraus ergeben. Sollte sich eine Technologie aus Ihrer Sicht überhaupt nicht für eine Funktionalität eignen, muss diese Entscheidung in der Dokumentation begründet werden.

Leistungsanalyse

Erstellen Sie eine aussagekräftige Analyse der Laufzeiten und Skalierbarkeit aller implementierten Funktionen. Ihre Analyse sollte beinhalten:

- Messungen verschiedener Dimensionen
- Vergleiche zwischen *sequentiell* - *OpenMP* - *MPI* - *GPU*
- Variationen der Parameter (Textgröße, Suchbegriffe)
- Diagramme erstellen, z.B. Laufzeit für verschiedene Parameterwerte, Speedup-Kurven, etc.
- Interpretation der Messergebnisse
- Erklärungen, wie die Speicherhierarchie das Verhalten beeinflusst

Dokumentation

Erstellen Sie eine Projekt-Dokumentation im Ordner **doc/** als **PDF**:

- Überblick über das Projekt, Architektur und Aufbau
- Beschreibung der Implementierungsentscheidungen: "Was wurde wann, warum gemacht?"
- Hinweise zur Parallelisierung (Granularität, Grade, Operationen, Muster)
- Verwendete Datenstruktur und Hinweis auf die Caches
- Anleitung zum Bauen und Ausführen des Projekts
- Leistungsanalyse mit Laufzeitdiagrammen und Interpretationen
- Begründung zu den verwendeten Technologien
- Möglichst viele visuelle Ergebnisse, sofern möglich
- Beschreibung zusätzlicher Libraries, sofern verwendet
 - exakte Version und Downloadquelle
 - Installationshinweise

Abgabe

- **Deadline** 06.02.2026, 23:59 Uhr.
 - Es zählt der Zeitstempel des letzten Commits auf dem **main**-Branch in Github.
- **Projektdateien**
 - Legen Sie alle *.sln* und *.vcxproj* Dateien bei.
 - Nutzen Sie primär Visual Studio und den MSVC-Compiler, es sei denn, Sie haben zuvor eine andere Umgebung abgesprochen.
- **Funktionalität**
 - Alle Funktionalitäten müssen vollständig und korrekt implementiert sein. Die Umsetzung muss sequentiell und mit mindestens einer parallelen Technologie erfolgt sein.
- **Dokumentation**
 - Muss als PDF im **doc/** Ordner liegen
 - Andere Formate werden nicht akzeptiert